

Rapport initiation à la recherche: l'Apprentissage Multi-Tâche

Gabriel Legout

29 mai 2026

Résumé

Dans ce document, nous commençons par décrire et analyser des techniques d'apprentissage multi-tâche dans le cadre linéaire en se basant sur l'article « Provable Meta-Learning of linear representation » [5] et en explicitant certains théorèmes et certaines techniques qui permettent de récupérer efficacement les paramètres d'estimation de notre modèle. Dans une seconde partie, nous étudions la généralisation de ces techniques en classification en étudiant la régression logistique et l'analyse discriminante linéaire.

Table des matières

1	Introduction	4
1.1	Conventions	5
2	Méthodes et hypothèses utilisées dans l'article	6
2.1	La méthode des moments	6
2.2	Les hypothèses 1 et 2	6
2.3	Méthode d'optimisation de bas rang	7
3	Détail algorithme 1 : Calcul et borne d'un estimateur de $\mathbf{B}$	7
3.1	Algorithme 1	7
3.1.1	Preuve du Lemme 2	7
3.1.2	Le lemme 2 et passage à une représentation de $\mathbf{B}$	10
3.1.3	De la représentation de $\mathbf{B}$ à l'algorithme 1	10
3.2	Une première borne sur $\hat{\mathbf{B}}$	11
3.2.1	Éléments de preuve du théorème 3	11
3.2.2	Un retour sur la notation $\sin(\mathbf{B}, \hat{\mathbf{B}})$	11
4	Apprentissage d'une nouvelle tâche : une estimation de $\hat{\alpha}$	12
4.1	Éléments de preuve du théorème 4	12
5	Généralisation de ces méthodes à la classification	13
5.1	Approche par la régression logistique	13
5.1.1	Régression logistique cas uni-tâche à deux classes	13
5.1.2	Approche naïve à la régression logistique multi-tâche binaire	14
5.1.3	Ce qui se fait dans la littérature sur la régression logistique multi-tâche	14
5.2	Approche par l'analyse discriminante linéaire	14
5.2.1	Analyse discriminante linéaire multitâche multiclasse (MT-MLDA)	15
5.2.2	Lien entre l'analyse discriminante linéaire et la régression multilinéaire	16
6	Conclusion	17

1 Introduction

Commençons d'abord par réintroduire les méthodes de regression linéaire et multi-linéaire ainsi que les différents enjeux associés dans les méthodes d'apprentissages.

D'abord, de manière classique, on peut noter un modèle de regression linéaire unidimensionnel de la manière suivant :

$$y_i = x_i \alpha + \epsilon_i$$

Avec, $y_i \in \mathbb{R}, x_i \in \mathbb{R}, \epsilon_i \in \mathbb{R}$. On a donc une liste de points $(x_i)_{i \in [0, n]}$, $n \in \mathbb{N}$ auquel on associe un unique α qui va être calculer selon une méthode quelconque (on peut chercher α tel qu'il minimise la somme résiduelle des carrés, auquel cas on aura y_i qui sera une prédiction au sens des moindres carrés) et va nous permettre de prédire un y_i qui n'est pas dans le domaine de points initial mais qui répond aux mêmes contraintes sur la tâche considérée.

Comme tous les modèles de régression, il faut connaître la fonction suivie par les donnés afin de pouvoir les modéliser, et en particulier, il faut que les donnés suivent une même "fonction" qui est exprimable dans le modèle.

De manière générale, on peut effectuer la généralisation suivante. On considère l'expérience statistique engendrée par l'observation :

$$(\mathbf{X}_1, y_1), \dots, (\mathbf{X}_n, y_n)$$

où :

$$y_i = r(\vartheta, \mathbf{X}_i) + \epsilon_i$$

Avec $i \in [1, n]$, les variables aléatoires $(\mathbf{X}_i, y_i)$ sont indépendantes et de même loi à valeur dans $\mathbb{R}^k \times \mathbb{R}$ et $\vartheta \in \Theta \subset \mathbb{R}^d$ le paramètre inconnu.

On va ensuite se passer dans le cas d'un design déterministe en posant l'hypothèse que la loi des covariables $\mathbf{X}_i$ ne dépend pas de ϑ . Ceci revient alors à remplacer $(\mathbf{X}_i, y_i)$ par $(\mathbf{x}_i, y_i)$. On peut le voir si la loi des y_i admet un moment d'ordre 1, on définit la fonction de régression $r(\vartheta, \cdot) : \mathbb{R}^k \rightarrow \mathbb{R}$ en posant :

$$r(\vartheta, \mathbf{x}) = \mathbb{E}_\vartheta[y_i \mid \mathbf{X}_i = \mathbf{x}], \quad \mathbf{x} \in \mathbb{R}^k$$

On peut alors écrire : $y_i = \mathbb{E}_\vartheta[y_i \mid \mathbf{X}_i = \mathbf{x}] + y_i - \mathbb{E}_\vartheta[y_i \mid \mathbf{X}_i = \mathbf{x}]$, avec $\epsilon = y_i - \mathbb{E}_\vartheta[y_i \mid \mathbf{X}_i = \mathbf{x}]$, on peut alors vérifier qu'on a bien $\mathbb{E}_\vartheta[\epsilon \mid \mathbf{X}_i = \mathbf{x}] = 0$.

Dans la suite, on pourra omettre le ϑ de $\mathbb{E}_\vartheta$ car il n'y a pas d'ambiguïté.

On voit alors que pour obtenir le premier modèle de régression linéaire (à une dimension), il suffit de poser $r = \vartheta = \alpha$. On peut maintenant généraliser en considérant que nos $\mathbf{x}_i$ sont des vecteurs. On va donc avoir :

$$y_i = x_{i,1}\alpha_1 + \dots + x_{i,k}\alpha_k + \epsilon_i$$

D'où en posant : $\vartheta = (\alpha_1, \dots, \alpha_k)$ et $r(\vartheta, \mathbf{x}_i = (x_{i,1}, \dots, x_{i,k})) = x_{i,1}\alpha_1 + \dots + x_{i,k}\alpha_k$

$$y_i = \mathbf{x}_i \vartheta^T + \epsilon_i$$

Qu'on peut réécrire :

$$y_i = \vartheta \mathbf{x}_i^T + \epsilon_i (\text{À voir ce qu'on décide de choisir comme dimensionnement})$$

Cependant, on voit que ce modèle aboutit à un nombre considérable de paramètres ce qui peut entraîner au coût de calcul énorme. De plus, avec l’hypothèse selon laquelle les entrées contiennent suffisamment d’information pour faire de la prédiction sur plusieurs tâches, il paraît raisonnable de considérer que certaines de ces tâches contiennent des caractéristiques communes parmi les entrées. Ce qu’on peut faire c’est imaginer avoir des paramètres communs à toutes les tâches et avoir des coefficients d’ajustement, par tâches, pour permettre une meilleure estimation. On va donc utiliser le modèle suivant :

$$y_i = \mathbf{x}_i^T \mathbf{B} \boldsymbol{\alpha}_{t(i)} + \epsilon_i$$

Dans ce modèle, on dispose d’un vecteur d’entrée comprenant d variables et de vecteurs de paramètres $\boldsymbol{\alpha}_{t(i)}$ spécifiques à une tâche $t(i)$ permettant de prévoir la sortie y_i . On va donc numéroté les tâches dans $I = \{1, \dots, T\}$ et donc $t(i) \in I$

De plus, contrairement à un modèle linéaire classique, on dispose d’une matrice $\mathbf{B}$, **commune** à toutes les tâches qui comprend des caractéristiques communes à plusieurs tâches permettant de mutualiser l’apprentissage et la prédiction y_i . Les indices $t(i)$, permettent simplement d’indiquer les tâches.

Tout l’enjeu de l’article et de montrer qu’il existe des méthodes simples, sous certaines bonnes hypothèses, pour récupérer un estimateur $\hat{\mathbf{B}}$ de la matrice $\mathbf{B}$ efficacement et puis de montrer qu’on a des meilleures estimations avec un coût plus faible qu’en cherchant uniquement des $\boldsymbol{\alpha}_t$. L’article se décompose donc en deux grandes parties : d’abord la phase de ”Meta-Learning” où on va essayer de trouver $\hat{\mathbf{B}}$ avec suffisamment de précision et avec un algorithme simple et efficace, puis la phase de ”Meta-Test” qui va permettre de montrer que le calcul de $\hat{\mathbf{B}}$ va permettre de transférer une part de l’apprentissage à une nouvelle tâche $T + 1$ en estimant $\boldsymbol{\alpha}_{T+1}$.

1.1 Conventions

On s’efforcera, tout au long de ce rapport, à suivre les notations de l’article [5] dont on fait l’analyse et dont on détaille les preuves plus loin.

Par soucis de clarté, on va identifier $\mathbb{R}^n$ aux matrices lignes, donc les notations de l’article nous donnent : $\mathbf{x}_i \in M_{d,1}(\mathbb{R})$ et donc $\mathbf{x}_i^T \in M_{1,d}(\mathbb{R})$. On a donc, avec ces conventions, $\mathbf{B} \in M_{d,r}(\mathbb{R})$ et $\boldsymbol{\alpha}_{t(i)} \in M_{r,1}(\mathbb{R})$ afin d’avoir $y_i \in \mathbb{R}$ et $\epsilon_i \in \mathbb{R}$.

On s’autorisera parfois à noter $t(i) = t$ qui restera implicitement une fonction de i à valeur dans $I = \{1, \dots, T\}$ afin d’alléger les notations.

Les $(\mathbf{x}_i)$ représentent des vecteurs observations. Quand ça sera nécessaire (pour choisir un représentant pour une espérance car ils suivent tous la même loi par exemple), on s’autorisera à noter $\mathbf{x}_1 = \mathbf{x}$ un vecteur quelconque de $(\mathbf{x}_i)$ pour alléger encore une fois les notations. Il conviendra donc de distinguer $\mathbf{x}_i$ (en gras) qui sera le i -ième vecteur d’observation et x_i qui sera la i -ième composante d’un vecteur quelconque.

Les lettres majuscules désignent toujours des matrices, quelles soient en gras ou non. Le gras permet soit de coller aux notations de l’article soit de distinguer les composantes des vecteurs avec les vecteurs en eux-mêmes.

Ensuite, dans tout ce document, le symbole $\hat{\cdot}$ (chapeau) au-dessus d'une lettre désignera un estimateur de l'objet considéré. Nous passerons sur le détail des convergences dans la suite de ce texte et on supposera que nous manipulerons uniquement des estimateurs convergents et on notera donc directement ces estimateurs avec un $\hat{\cdot}$ sans plus de justifications.

De plus, quand on manipulera des espérances, on posera l'hypothèse d'ancillarité du design (les observations $\mathbf{x}_i$), c'est-à-dire que la loi des $\mathbf{x}_i$ ne dépend pas des paramètres $\mathbf{B}$ et α que l'on va estimer. Ceci permettra de considérer des espérances selon la loi de y sans que cela ne soit spécifié.

On pourra se permettre de parler de "matrices orthogonales" pour des matrices dont les colonnes forment une base orthogonale de l'espace considéré sans pour autant que cette matrice soit carré.

2 Méthodes et hypothèses utilisées dans l'article

Nous allons ici exposer les hypothèses faites sur le modèle et sur les entrées ainsi que des méthodes générales qui vont être utilisées pour montrer les résultats important tout au long de l'article.

2.1 La méthode des moments

Le but de la méthode des moments est d'estimer un paramètre λ en remplaçant son moment théorique par un moment empirique. On a alors que le moment empirique de la variable aléatoire converge presque-sûrement vers l'espérance de la variable aléatoire par la loi forte des grands nombres.

Soit g une fonction mesurable et $m = \mathbb{E}[g(X)]$, et des variables aléatoires i.i.d. $X_1, \dots, X_n$ dépendantes d'un paramètre λ . Supposons qu'il existe un $\mathcal{C}^1$ -difféomorphisme sur un ouvert de $\mathbb{R}$ ϕ , tel que $\phi(\lambda) = m$. On peut alors écrire $\lambda = \phi^{-1}(m)$. Par la loi forte des grands nombres, en posant $\hat{m}_n = \frac{1}{n} \sum_{i=1}^n g(X_i)$, on a $\hat{m}_n \xrightarrow{p.s.} m$ et puis par le théorème de continuité, en considérant l'estimateur $\hat{\lambda} = \phi^{-1}(\hat{m}_n)$ on a $\hat{\lambda} \xrightarrow{p.s.} \lambda$ et donc $\hat{\lambda}$ est un estimateur fortement consistant de λ . Par exemple : Supposons que X suit une loi exponentielle de paramètre λ , g est l'identité, $m = \mathbb{E}[X] = \frac{1}{\lambda}$ et on a $\phi(x) = \frac{1}{x}$ qui est bien un $\mathcal{C}^1$ -difféomorphisme sur $\mathbb{R}^+$ donc on peut appliquer la méthode :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et} \quad \bar{X} = \hat{m}_n$$

D'où

$$\frac{1}{\hat{\lambda}} = \bar{X} \Leftrightarrow \hat{\lambda} = \frac{1}{\bar{X}}$$

Par conséquent, en disposant seulement des observations et ayant une expression du moment théorique (c'est-à-dire en connaissant la fonction ϕ), on peut estimer le paramètre que l'on cherche.

2.2 Les hypothèses 1 et 2

Hypothèse 1 : Sous-exponentielle et réduction des $\mathbf{x}_i$ Les vecteurs $\mathbf{x}_i$ sont indépendants et identiquement distribués (iid), d'espérance nulle et de covariance $\mathbb{E}[\mathbf{x}\mathbf{x}^T] = \mathbf{I}_d$ avec $\mathbb{E}[e^{\mathbf{v}^T \mathbf{x}_i}] \leq$

$e^{\frac{\|\mathbf{v}^2\|}{2}}$. De plus, les variables aléatoire du bruit, ϵ_i sont iid, de variance égale à 1 et indépendants des $\mathbf{x}_i$

L'hypothèse d'avoir les $\mathbf{x}_i$ centrés réduits est nécessaire à presque toutes les preuves pour simplifier les moments théoriques d'ordre 1 ou simplifier par l'identité les produits $\mathbf{x}\mathbf{x}^T$ dans des espérances. De plus, on considère qu'ils sont indépendants et identiquement distribués (iid). On rajoute parfois en plus l'hypothèse que les $\mathbf{x}_i$ suivent une loi normale centrée réduite. L'hypothèse de sous-exponentielle permet d'appliquer des inégalités de concentration.

Hypothèse 2 : Normalisation des tâches Soit $t(i) \in I$, on suppose que $\|\alpha_{t(i)}\| \leq \Theta(1)$. De plus, les r -premières valeurs propres de $\frac{A^T A}{t(i)}$ sont non nulles.

L'hypothèse 2 permet de garantir que les tâches ne sont pas trop différentes et que donc il est possible de reconstruire la matrice $\mathbf{B}$ (qu'il y ait suffisamment d'information, ou de signal si on parle de reconstruction de phase, par rapport au bruit)

2.3 Méthode d'optimisation de bas rang

à remplir

3 Détail algorithme 1 : Calcul et borne d'un estimateur de $\mathbf{B}$

On va donc décrire et expliciter ici certains points des preuves et de la méthode qui va nous permettre de calculer $\hat{\mathbf{B}}$.

3.1 Algorithme 1

L'algorithme 1 nous dit que faire une décomposition en valeurs singulières (ici la matrice est évidemment carré symétrique et même définie positive donc cela revient à la diagonaliser en prenant les valeurs propres dans le sens décroissant par le théorème spectral) de la matrice $M = \frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T$ on obtient $\hat{\mathbf{B}}$ comme matrice de la base dans laquelle M est diagonale.

On peut alors se poser deux questions : pourquoi M permet de construire un estimateur $\hat{\mathbf{B}}$ de $\mathbf{B}$ et avec quelle précision le fait-elle ?

3.1.1 Preuve du Lemme 2

Le lemme 2 nous dit, qu'en supposant les hypothèses 1 et 2 décrites à 2.2 et en supposant en plus que les $\mathbf{x}_i$ sont gaussiens (loi normale d'espérance nulle et de variance égale à l'identité) on a :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T \right] = 2\bar{\Gamma} + (1 + \text{tr}(\bar{\Gamma}))\mathbf{I}_d$$

Avec $\bar{\Gamma} = \frac{1}{n} \sum_{i=1}^n \Gamma_i$ et $\Gamma_i = \mathbf{B} \boldsymbol{\alpha}_t \boldsymbol{\alpha}_t^T \mathbf{B}^T$. On définit en plus $\bar{\Lambda} = \frac{1}{n} \sum_{i=1}^n \boldsymbol{\alpha}_t \boldsymbol{\alpha}_t^T$

Preuve :

On va commencer par remarquer que $y_i \in \mathbb{R}$ donc $y_i = y_i^T$ et en particulier $y_i^2 = y_i y_i^T$ (1) et si on a une famille $(\mathbf{z}_i)$ des vecteurs qui suivent la même loi et sont indépendants et identiquement distribués, si $\bar{\mathbf{z}} = \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i$ alors $\mathbb{E}[\bar{\mathbf{z}}] = \mathbb{E}[\mathbf{z}]$ (2). On rappelle que t reste une fonction de i , mais on ne le note pas pour alléger les notations (en particulier, les sommes sur i dans les calculs suivant sont effectivement indicés par i).

Maintenant en utilisant (1) :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T \right] = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i y_i^T \mathbf{x}_i \mathbf{x}_i^T \right] = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i^T \mathbf{B} \boldsymbol{\alpha}_t \boldsymbol{\alpha}_t^T \mathbf{B}^T \mathbf{x}_i + \epsilon_i \epsilon_i^T) \mathbf{x}_i \mathbf{x}_i^T \right]$$

Puis en développant :

$$\mathbb{E} \left[\left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^T \mathbf{B} \boldsymbol{\alpha}_t \boldsymbol{\alpha}_t^T \mathbf{B}^T \mathbf{x}_i \mathbf{x}_i^T \right) + \left(\frac{1}{n} \sum_{i=1}^n \epsilon_i \epsilon_i^T \mathbf{x}_i \mathbf{x}_i^T \right) \right] = \mathbb{E} \left[\mathbf{x}^T \left(\frac{1}{n} \sum_{i=1}^n \mathbf{B} \boldsymbol{\alpha}_t \boldsymbol{\alpha}_t^T \mathbf{B}^T \right) \mathbf{x} \mathbf{x}^T \right] + \mathbb{E}[\epsilon \epsilon^T \mathbf{x} \mathbf{x}^T]$$

Et comme d'une part on identifie $\bar{\Gamma}$ et de l'autre on utilise (2) car on vérifie les hypothèses 1 (en particulier que les ϵ_i et $\mathbf{x}_i$ sont indépendants) et 2, on a finalement :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T \right] = \mathbb{E}[\mathbf{x}^T \bar{\Gamma} \mathbf{x} \mathbf{x}^T] + \mathbf{I}_d$$

On a : $\bar{\Gamma} = \mathbf{B} \bar{\Lambda} \mathbf{B}^T$ comme $\mathbf{B}$ est une matrice orthogonale. Cependant, elle n'est pas orthogonale au sens conventionnel, car elle n'est pas carrée. On peut éventuellement remarquer que c'est toujours possible, même si la matrice n'est pas carrée de considérer que les vecteurs colonnes sont orthogonaux (ils sont tous de même dimension) et si $r < d$, on a trivialement une famille libre de r vecteurs dans $\mathbb{R}^d$ (si $r > d$, ça ne marche évidemment pas, mais ici on suppose qu'on a plus de points que de tâches sinon ça n'a pas de sens.)

On peut alors considérer $\bar{\Gamma} = \begin{bmatrix} \mathbf{B} & \mathbf{B}_\perp \end{bmatrix} \begin{bmatrix} \bar{\Lambda} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{B}^T \\ \mathbf{B}_\perp^T \end{bmatrix} = \tilde{\mathbf{B}} \begin{bmatrix} \bar{\Lambda} & 0 \\ 0 & 0 \end{bmatrix} \tilde{\mathbf{B}}^T$ tel que $\tilde{\mathbf{B}}$ est bien une matrice carrée et orthogonale (qui existe par le théorème de la base incomplète car nous sommes en dimension finie) qui est simplement l'expression de $\bar{\Gamma}$ dans l'espace $M_{d,d}(\mathbb{R})$ (qui contient $M_{d,r}(\mathbb{R})$) et qui va simplement ajouter des 0 au spectre de $\bar{\Gamma}$ (et donc celui de $\bar{\Lambda}$). Or $\mathbf{B}$ est de rang au plus r et on s'intéresse seulement aux r -premières valeurs propres donc ça ne change pas les propriétés de notre décomposition. On utilisera donc $\mathbf{B}$ dans la suite à la place de $\tilde{\mathbf{B}}$ sans que cela ne change quelque chose à la validité des calculs car on a simplement besoin de vérifier l'égalité des spectres et c'est chose faite.

Maintenant, une matrice orthogonale est une matrice de changement de base orthogonale, donc $\text{Sp}(\bar{\Gamma}) = \text{Sp}(\bar{\Lambda})$ et donc on peut dire "quelles se comportent de la même manière" au sens des transformations dans l'espace. On va donc noter σ_i leurs valeurs propres. On va noter $Q \in \mathbb{O}_d(\mathbb{R})$ la matrice de la base orthogonale dans laquelle $\bar{\Lambda}$ est diagonale.

$$\mathbb{E}[\mathbf{x}^T \bar{\Lambda} \mathbf{x} \mathbf{x}^T] = \mathbb{E}[\mathbf{x}^T Q \text{Diag}(\sigma_1, \dots, \sigma_r) Q^T \mathbf{x} \mathbf{x}^T]$$

Mais, il faut garder à l'esprit que $\mathbf{x}^T \bar{\Lambda} \mathbf{x}^T \in \mathbb{R}$ et donc que $\mathbf{x}^T Q \in \mathbb{R}^d$. Par conséquent, on peut écrire $\mathbf{x}^T Q \text{Diag}(\sigma_1, \dots, \sigma_r) Q^T \mathbf{x} = \mathbf{x}^T Q (\mathbf{x}^T Q \text{Diag}(\sigma_1, \dots, \sigma_r))^T$ et si on note $Q = (\mathbf{v}_1, \dots, \mathbf{v}_r)$, on a $\mathbf{x}^T Q = (\mathbf{x}^T \mathbf{v}_1, \dots, \mathbf{x}^T \mathbf{v}_r)$ et donc $\mathbf{x}^T Q \text{Diag}(\sigma_1, \dots, \sigma_r) = (\sigma_1 \mathbf{x}^T \mathbf{v}_1, \dots, \sigma_r \mathbf{x}^T \mathbf{v}_r)$.

Donc comme $\mathbf{x}^T Q(\mathbf{x}^T Q \text{Diag}(\sigma_1, \dots, \sigma_r))^T$ est un produit scalaire de deux vecteurs réel (car $\mathbf{x}^T \sigma_i \in \mathbb{R}$) : $\mathbf{x}^T \bar{\Lambda} \mathbf{x} = \sum_{i=1}^r \sigma_i (\mathbf{x}^T \mathbf{v}_i)^2$ et donc par linéarité de l'espérance :

$$\mathbb{E}[\mathbf{x}^T \bar{\Lambda} \mathbf{x}] = \sum_{i=1}^r \sigma_i \mathbb{E}[(\mathbf{x}^T \mathbf{v}_i)^2]$$

Il suffit maintenant de trouver un moyen de calculer $\mathbb{E}[(\mathbf{x}^T \mathbf{v}_i)^2]$ pour conclure. Or dans l'article, on explique que le fait que les $\mathbf{x}_i$ soient iid et gaussiens nous permet de dire que la gaussienne est isotropique (aligné selon un axe du repère) et que sa covariance s'écrit $\Sigma = \sigma^2 \mathbf{I}_d$ et comme dans notre cas, la matrice de covariance est multiplié par un réel $\mathbf{x}^T \mathbf{v}_i$ qui dépend de $\mathbf{x}$ (donc qu'on ne peut pas sortir de l'espérance) et d'un vecteur d'une base orthogonal, "il suffit" de calculer $\mathbb{E}[(\mathbf{x}^T \mathbf{e}_1)^2]$ avec $\mathbf{e}_1$ un vecteur de la base canonique de $\mathbb{R}^d$ et ensuite de multiplier par $\mathbf{v}_i$ ce qui aura pour effet de faire une rotation sur la distribution et de retrouver celle qui nous intéresse. On va vérifier cette intuition par un calcul explicite pour un $\mathbf{v}_i$ quelconque.

On a, $\mathbf{x}^T \mathbf{e}_1 = x_1 \in \mathbb{R}$:

$$\mathbb{E}[(\mathbf{x}^T \mathbf{e}_1)^2] = \mathbb{E}[x_1^2] = \mathbb{E}[x_1^2 x_i x_j]_{ij}$$

$$\mathbb{E}[x_1^2 x_i x_j]_{ij} = \begin{cases} \mathbb{E}[x_1^4] = 3 & \text{si } i = j = 1 \\ \mathbb{E}[x_1^2 x_i^2] = 1 & \text{si } i = j \neq 1 \\ \mathbb{E}[x_1^2 x_i x_j] = 0 & \text{si } i \neq j \end{cases}$$

En effet, $\mathbf{x} \sim \mathcal{N}(0, \mathbf{I}_d)$ donc $\|\mathbf{x}\|^2 \sim \chi^2(d)$ (à d degré de liberté). Donc pour le cas particulier x réel, on utilise les formules d'espérance et de variance pour $\chi^2(1)$: $\text{Var}(x_1^2) = \mathbb{E}[x_1^4] - (\mathbb{E}[x_1^2])^2 \Leftrightarrow \mathbb{E}[x_1^4] = 2 + 1 = 3$. Pour les deux autres moments, c'est simplement de la manipulation de vecteurs indépendants ou non. Donc :

$$\mathbb{E}[(\mathbf{x}^T \mathbf{e}_1)^2] = 2e_1 e_1^T + \mathbf{I}_d$$

Puis, on va effectuer la même méthode pour $\mathbf{v}_i$ (donc un vecteur colonne de Q quelconque) qu'on va noter $\mathbf{v}$ dans la suite pour alléger les notations (et donc v_j désignera la j -ième composante de $\mathbf{v}_i$). En utilisant la formule du multinôme de Newton :

$$(\mathbf{x}^T \mathbf{v})^2 = \left(\sum_{j=1}^d x_j v_j \right)^2 = \sum_{0 \leq i, j \leq d} v_i v_j x_i x_j$$

Et on note comme les v_j sont des scalaires, par linéarité de l'espérance, on a :

$$\mathbb{E}[(\mathbf{x}^T \mathbf{v})^2] = \sum_{0 \leq i, j \leq d} v_i v_j \mathbb{E}[x_i x_j]$$

On sépare alors le cas $i = j$ et par la formule du multinôme, il suffira de prendre 2 fois la somme dans l'ordre strictement croissant des lignes par exemple. ($0 \leq i < j \leq d$).

Mais le cas $i = j$ donne directement $\sum_{i=1}^d v_i^2 \mathbb{E}[x_i^2] = \sum_{i=1}^d v_i^2 (2e_i e_i^T) + \|\mathbf{v}\|^2 \mathbf{I}_d$ (il suffit de prendre $1 = i$ dans ce qu'on a fait plus haut.) Mais par le théorème spectral, car nous sommes dans des espaces euclidiens, on peut diagonaliser en base orthonormée et quitte à en changer, on peut la prendre normée selon la norme issue du produit scalaire donc $\|\mathbf{v}\|^2 = 1$.

Ensuite, par une disjonction de cas sur la parité des moments similaire à ce qu'on a fait plus haut :

$$\mathbb{E}[(\mathbf{x}^T \mathbf{v})^2] = \sum_{i=1}^d v_i^2 (2e_i e_i^T) + \mathbf{I}_d + 2 \sum_{0 \leq i < j \leq d} v_i v_j e_i e_j^T$$

$$\text{Or,} \quad 2 \sum_{0 \leq i < j \leq d} v_i v_j e_i e_j^T = 2 \mathbf{v} \mathbf{v}^T \quad \text{donc :}$$

$$\mathbb{E}[(\mathbf{x}^T \mathbf{v})^2 \mathbf{x} \mathbf{x}^T] = 2 \mathbf{v} \mathbf{v}^T + \mathbf{I}_d$$

On trouve alors, en prenant la décomposition en vecteur propre ci-dessus dans l'autre sens (en effet, si σ_i sont des valeurs propres et $\mathbf{v}_i$ les vecteurs propres associés, une décomposition de la matrice se note $\sum_{i=1}^r \sigma_i \mathbf{v}_i \mathbf{v}_i^T$) et en sommant :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T \right] = 2\bar{\Gamma} + \text{tr}(\bar{\Gamma}) \mathbf{I}_d + \mathbf{I}_d = 2\bar{\Gamma} + (1 + \text{tr}(\bar{\Gamma})) \mathbf{I}_d$$

Ce qui conclut la preuve du Lemme 2.

3.1.2 Le lemme 2 et passage à une représentation de $\mathbf{B}$

Maintenant qu'on a trouvé une expression utilisable de l'espérance théorique, on va montrer comment il va permettre de retomber sur $\mathbf{B}$. En posant $\gamma = 1 + \text{Tr}(\bar{\Gamma}) = 1 + \text{Tr}(\bar{\Lambda})$

$$\Omega = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T \right] = 2\bar{\Gamma} + (1 + \text{tr}(\bar{\Gamma})) \mathbf{I}_d = 2\mathbf{B} \bar{\Lambda} \mathbf{B}^T + \gamma \mathbf{I}_d$$

Mais $\bar{\Lambda}$ est trivialement une matrice symétrique définie positive donc elle est aussi diagonalisable, donc $\exists Q \in \mathbb{O}_d(\mathbb{R})$ tel que $\bar{\Lambda} = Q D_{(\bar{\Lambda})} Q^T$ et comme vu plus haut, une matrice orthogonale et une matrice de passage dans une base orthogonale donc si Ω reste diagonal dans cette base alors la base a les mêmes propriétés :

$$\Omega = \mathbf{B} Q D_{(\bar{\Lambda})} \mathbf{B}^T Q^T + \gamma \mathbf{I}_d = \tilde{\mathbf{B}} D_{\bar{\Lambda}} \tilde{\mathbf{B}}^T + \gamma \mathbf{I}_d$$

Or, $\gamma \mathbf{I}_d$ commute avec toutes les matrices et elle est symétrique définie positive (hypothèse 2) donc on peut appliquer le théorème de réduction simultané des endomorphismes symétriques.

En particulier, comme $\gamma \mathbf{I}_d$ est déjà diagonale, alors γ est sa seule valeur propre et comme $2\bar{\Gamma}$ est déjà diagonalisée en base orthonormée, on sait que la base commune se trouve dans l'espace de $\tilde{\mathbf{B}}$, donc quitte à renommer ou normer les bases, on choisi $\tilde{\mathbf{B}}$ comme matrice de diagonalisation commune.

Comme $\gamma > 0$, ça ne change pas l'ordre des valeurs propre de Ω . Donc les r -premières valeurs propres de Ω sont $w_i = \sigma_i + \gamma$ et puis les $(d - r)$ -autres sont exactement γ .

Par conséquent, diagonaliser Ω nous donne bien des vecteurs propres associés à l'espace des vecteurs de $\mathbf{B}$.

3.1.3 De la représentation de $\mathbf{B}$ à l'algorithme 1

Maintenant qu'on a montré que $\Omega = \tilde{\mathbf{B}} \tilde{D}_{\bar{\Lambda}} \tilde{\mathbf{B}}$, il reste à montrer que $M = \hat{\mathbf{B}} D_1 \hat{\mathbf{B}}^T$.

Cela revient à montrer que la méthode des moments permet effectivement de trouver un bon estimateur de $\mathbf{B}$. Pour ce faire, le théorème 7 garanti que l'erreur entre M et $\Omega = \mathbb{E}[\frac{1}{n} \sum_{i=1}^n y_i^2 \mathbf{x}_i \mathbf{x}_i^T]$ est suffisamment petite pour faire fonctionner le théorème 3 (qui dit que dans ces conditions, $\hat{\mathbf{B}}$ est bien un bon estimateur de $\mathbf{B}$.)

3.2 Une première borne sur $\hat{\mathbf{B}}$

3.2.1 Éléments de preuve du théorème 3

Évidemment, selon les données et la manière de calculer les différentes matrices, il se peut qu'on trouve une matrice $\hat{\mathbf{B}}$ très différente de $\mathbf{B}$ mais ça n'a pas d'importance. Ce qui compte, c'est qu'elles représentent le même espace (ou en tout cas, on veut estimer la proximité entre les deux sous espaces décrits par les matrices, ie borner la différence entre les deux espaces), on cherche donc un moyen de comparer les espaces à partir d'une représentation par une matrice dans une certaine base.

Pour expliquer la stratégie de preuve du théorème 3, on va déjà expliquer le théorème de Davis-Kahan qui va nous permettre de comparer les sous espaces comme expliqué plus haut. En se basant sur un cours de Columbia University [3] par Daniel Hsu, on va relier les notations $\sin(\hat{\mathbf{B}}, \mathbf{B})$ et $\|\hat{\mathbf{B}}_{\perp}^T \mathbf{B}\|$.

On note $M = \Omega + E$ avec E bornée et on va les décomposer en somme d'actions sur des sous espaces orthogonaux :

$$\Omega = \mathbf{B} D_{\Omega} \mathbf{B}^T + \mathbf{B}_1 D_{\Omega_1} \mathbf{B}_1^T \quad \text{et} \quad M = \hat{\mathbf{B}} D_{\Omega} \hat{\mathbf{B}}^T + \hat{\mathbf{B}}_1 D_{\Omega_1} \hat{\mathbf{B}}_1^T$$

avec $\mathbf{B} \in S$ tel que S est le sous espace des r -premières valeurs propres de Ω et $\mathbf{B}_1 \in S^{\perp}$ le complémentaire orthogonal (qui existe par le théorème spectral en dimension finie) ce qui nous permet d'avoir une décomposition selon les valeurs propres de Ω qui nous intéresse. On peut alors montrer (cf. article en lien), que la proximité entre les sous espaces qui nous intéresse revient à minimiser la norme $\|\hat{\mathbf{B}}_1^T \mathbf{B}\|$. Ce qui nous donne le théorème de Davis-Kahan :

$$\|\hat{\mathbf{B}}_1^T \mathbf{B}\| = \|\hat{\mathbf{B}}_{\perp}^T \mathbf{B}\| \leq \frac{\|\hat{\mathbf{B}}_{\perp}^T E \mathbf{B}\|}{\delta}$$

Avec un δ tel que les valeurs propres de D_{Ω} et D_{Ω_1} soient différentes. Ici, on veut remplacer $\hat{\mathbf{B}}_1^T$ par $\hat{\mathbf{B}}_{\perp}^T$, car c'est la matrice utilisée dans l'article. En fait, ce sont les mêmes matrices. Dans le paragraphe au-dessus, on veut créer une décomposition dans des espaces orthogonaux. M est une approximation de Ω qu'on décompose en deux sous espaces, $\tilde{S}, \tilde{S}^{\perp}$. Ce qu'on espère (et qu'on veut pouvoir mesurer), c'est la proximité entre S et $\tilde{S}$. Lors de la décomposition, on a pris S (et donc $\tilde{S}$) comme l'espace des r -premières valeurs propres. Ainsi, la méthode garantie que peu importe la matrice $\hat{\mathbf{B}}_1^T$ choisie pour représenter $\tilde{S}^{\perp}$, la méthode ci-dessus permet de mesurer la différence (donc la distance) entre les deux espaces. Il est donc clair que par construction, $\hat{\mathbf{B}}_{\perp}^T$ convient (car c'est évidemment une matrice formée d'une base du complémentaire orthogonale de $\tilde{S}$.)

Il suffit alors de prendre δ tel que $\|E\| \leq \delta$ et comme $\hat{\mathbf{B}}_{\perp}^T$ et $\mathbf{B}$ sont des matrices orthogonales, on peut majorer l'inégalité par $\|E\|$ puis majorer l'erreur E , ce qui nous permet de conclure.

3.2.2 Un retour sur la notation $\sin(\mathbf{B}, \hat{\mathbf{B}})$

Comme expliqué au paragraphe précédent, il nous faut définir une notion de distance entre des sous-espaces afin de s'avoir si nos matrices sont proches dans le sens où elles génèrent des sous-espaces proches. Si on a deux sous-espaces Π et Ξ , caractérisé par des matrices respectives E et F qui sont formées de bases orthonormées de leur espace respectif. En reprenant les notations d'un cours de Carnegie-Mellon [1] : on peut écrire la décomposition en valeur singulière de $E^T F$ en notant $E^T F = U D V^T$ avec U, V des matrices orthonormales dans le sens où elles

sont formées de familles orthonormées et D une matrice diagonale tel que $D = \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_n \end{bmatrix}$,
on peut ensuite écrire $\theta_i = \cos^{-1}(\sigma_i)$ et donc $D = \cos(\Theta)$ avec $\Theta = \begin{bmatrix} \theta_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \theta_n \end{bmatrix}$. On a

donc $\|E^T F\| = \|\cos(\Theta)\|$, car U, V sont orthonormales. Et on a bien que $\cos(\Theta) = \cos(E, F)$. Cependant, $\forall i \in [1, n], \theta_i \in [0, \frac{\pi}{2}]$, donc si on range les θ_i dans l'ordre croissant, on a bien $\sin(\theta_1) \leq \|E_\perp^T F\|$ (la fonction $\sin(\cdot)$ renverse l'ordre sur $[0, \frac{\pi}{2}]$ mais reste positive). Or, l'article définit $\sin(E, F) = \sin(\theta_1)$. On appelle alors θ_1 l'angle principal entre Π et Ξ . Si $\sin(\theta_1)$ est petit, ça veut dire que le plus grand angle entre les deux espaces est proche de $\frac{\pi}{2}$ et donc que $\hat{\mathbf{B}}_\perp$ et $\mathbf{B}$ sont bien orthogonales et donc que $\hat{\mathbf{B}}$ est proche de $\mathbf{B}$.

Il suffit maintenant de prendre la norme infinie et on obtient le résultat.

Une autre preuve, plus calculatoire, est trouvable dans un cours sur les méthodes spectrales en data science de Princeton [2].

4 Apprentissage d'une nouvelle tâche : une estimation de $\hat{\alpha}$

4.1 Éléments de preuve du théorème 4

Le but de ce théorème est de montrer que l'algorithme 2 permet d'apprendre une nouvelle tâche (en calculant un α_{T+1}) à partir d'une bonne estimation de $\hat{B}$ (une bonne estimation étant ici définie comme une estimation qui respecte le théorème 3, donc toute estimation faite à partir de l'algorithme 1 qui respecte nos hypothèses de départ.)

On va utiliser un estimateur au sens des moindres carrés défini comme il suit :

$$\hat{\alpha} = \arg \min_{\alpha} \|\mathbf{y} - \mathbf{X}\hat{\mathbf{B}}\alpha\|^2$$

Ici, $\mathbf{y}$ est un vecteur colonne qui contient toutes les réponses du jeu d'apprentissage et $\mathbf{X}$ est une matrice qui concatène tous les vecteurs des observations du jeu d'apprentissage. À priori, $\mathbf{X}\hat{\mathbf{B}}$ n'est pas injective donc on n'a pas unicité de $\hat{\alpha}$. On va alors utiliser une démonstration algébrique afin de démontrer l'existence (et oui parce que l'utilisation du mot clé min est maladroite, car on ne sait pas, à priori, si on a l'existence (et même l'unicité) d'un minimum ou non) et de caractériser ce minimum à l'aide des données du problème. On peut en effet utiliser les théorèmes d'existence de pseudo-solutions de systèmes surdéterminés. Ces théorèmes nous donne :

$$(\mathbf{X}\hat{\mathbf{B}})^T \mathbf{X}\hat{\mathbf{B}}\hat{\alpha} = (\mathbf{X}\hat{\mathbf{B}})^T \mathbf{y}$$

Une manière de voir que le théorème fonction est grâce au théorème de l'alternative qui nous donne : $\text{Im}(A^T) = \text{Im}(A^T A) = \ker(A)^\perp$. Il reste à montrer que $A^T A = (\mathbf{X}\hat{\mathbf{B}})^T \mathbf{X}\hat{\mathbf{B}}$ est inversible. C'est le cas si elle est définie positive : $\forall x \in \mathbb{R}^r, x \neq 0$:

$$(x | A^T A x) = x^T A^T A x = (Ax)^T (Ax) = \|Ax\|^2 > 0$$

On voit donc il suffit de montrer que $A = \mathbf{X}\hat{\mathbf{B}}$ est de rang supérieur ou égal à r . $\hat{\mathbf{B}}$ est une matrice orthogonale donc elle ne va pas modifier le rang, il suffit d'avoir $\text{rg}(\mathbf{X}) \geq r$ pour que $A^T A$

soit inversible. C'est le cas, car les $(x_i)_{[1, n_2]}$ qui forment les colonnes de $\mathbf{X}$ contiennent presque sûrement un sous famille génératrice de $\mathbb{R}^r$ (ils sont indépendants et identiquement distribué d'après l'hypothèse 1) et $n_2 \gg d \gg r$ (on a au moins $r \leq \frac{d}{2}$), de plus, par l'hypothèse 2, il nous faut que les $\mathbf{x}_i$ contiennent suffisamment d'information pour faire l'estimation des $\alpha_{t(i)}$. On peut donc écrire :

$$\hat{\alpha} = ((\mathbf{X}\hat{\mathbf{B}})^T \mathbf{X}\hat{\mathbf{B}})^{-1} (\mathbf{X}\hat{\mathbf{B}})^T \mathbf{y}$$

Ensuite, il suffit de poser $\mathbf{y} = \mathbf{X}\hat{\mathbf{B}}\alpha + \epsilon$ et d'utiliser l'expression de $\hat{\alpha}$ dans l'expression $\hat{\mathbf{B}}\hat{\alpha} - \mathbf{B}\alpha_0$, d'en prendre la norme au carré et d'utiliser les Lemmes 18 et 19 pour borner les termes et on obtient le théorème 4.

5 Généralisation de ces méthodes à la classification

Dans cette partie, nous allons regarder les possibilités pour étendre le modèle multi-tâches, avec lequel on a travaillé dans les sections du dessus, à des cas non linéaire. En particulier, nous allons en premier lieu aborder le cas de la classification binaire avec une régression logistique.

5.1 Approche par la régression logistique

Dans cette courte partie, nous allons rappeler la définition de la régression logistique puis définir une version multitâche en faisant une recherche bibliographique sur ce qui se fait dans la littérature.

5.1.1 Régression logistique cas uni-tâche à deux classes

On va prendre $\Omega = \{0, 1\}$ et $Y_i \in \Omega$ une variable aléatoire. Si on considère les covariables $\mathbf{x}_i = (x_1, \dots, x_n)^T$, telle que ces vecteurs correspondent aux réalisations successives (donc les observations) des variables aléatoires respectives. Comme dans l'introduction, on assimile les variables aléatoires à leur réalisation.

Si on note $\pi_i = \mathbb{P}(Y_i = 1 | \mathbf{x}_i)$, on fait l'hypothèse qu'il existe $\alpha \in M_n(\mathbb{R})$, alors $\ln(\frac{\pi}{1-\pi}) = \mathbf{x}_i^T \alpha$ et donc on peut exprimer la probabilité d'appartenance à la classe 1 :

$$\pi_i = \frac{1}{1 + e^{-(\mathbf{x}_i^T \alpha)}}$$

Ce modèle est un cas particulier de modèle linéaire généralisé, où on reprend l'interprétation de la régression comme une espérance conditionnelle qu'on essaye d'estimer par une fonction linéaire composée à une Ceci permet de construire un classifieur linéaire et nous permettra peut-être d'utiliser des méthodes comme l'analyse discriminante linéaire au moment du passage au multi-tâche dans les sections suivantes.

Dans le cas multi-classes (que nous n'aborderons pas ici dans un premier temps), il faudrait effectuer une transformation softmax des vecteurs $\mathbf{x}_i$ avant d'y appliquer la régression logistique.

Pour trouver les coefficients de α , on ne peut pas vraiment utiliser un estimateur des moindres carrés, à la place, on va chercher à maximiser la vraisemblance. On va calculer la vraisemblance qu'on définit comme :

$$\mathcal{L}(\alpha) = \prod_{i=1}^n \pi_i(\alpha)^{Y_i} (1 - \pi_i(\alpha))^{1-Y_i}$$

ou la log-vraisemblance :

$$\mathcal{LL}(\alpha) = \sum_{i=1}^n \log(\pi_i(\alpha))Y_i + \log(1 - \pi_i(\alpha))(1 - Y_i)$$

Et que l'on peut optimiser à l'aide de la méthode de Newton-Raphson.

5.1.2 Approche naïve à la régression logistique multi-tâche binaire

On va essayer de poser bêtement un modèle qui combine notre modèle multi-tâche et celui vu ci-dessus, et on va essayer d'estimer ses paramètres à l'aide des méthodes développés plus haut. On peut donc poser, avec les conventions des sections précédentes et en les appliquer au modèle de régression logistique vu plus haut :

$$\pi_i = \frac{1}{1 + e^{-(\mathbf{x}_i^T \mathbf{B} \alpha_{t(i)})}}$$

La question qui se pose maintenant, c'est de savoir dans quelle mesure peut-on obtenir une bonne approximation de $\mathbf{B}$ et de α afin de pouvoir faire apprendre le modèle.

5.1.3 Ce qui se fait dans la littérature sur la régression logistique multi-tâche

La plupart des articles que j'ai trouvés utilisent des modèles multi-classes en plus du multi-tâche ce qui complique les calculs et la recherche de méthode d'estimations des poids du modèle. C'est souvent des modèles à destination de la médecine pour faire de la prédiction du temps de survie de patient atteint de maladies graves comme le cancer. Le multi-tâche se fait d'ailleurs parfois sur les échelles de temps comme dans cet article pour la médecine [4] ou la tâche va être de prédire la probabilité de décès dans un intervalle de temps donné. Cependant, cet article ne va pas nous être d'une grande aide, car la méthode utilisée pour l'apprentissage des poids utilise de l'apprentissage profond. L'approche multi-tâche en termes de traitement sur des intervalles de temps semble être courante dans la bibliographie (j'ai même trouvé que ça), si bien que les modules R et Python des libraires scientifiques utilise cette implémentation dans ce qu'ils appellent une fonction MTLR (MultiTask Logistic Regression).

Ces librairies font référence à un article de prédiction de temps de survie der patients atteints de cancers (Yu et al. (2011)) [12] qui propose une minimisation de la fonction coût entropie croisé binaire par la méthode de Newton. Rien ne semble apparaitre dans la littérature scientifique au sujet d'optimisation de ce genre de modèle par une descente de gradient.

5.2 Approche par l'analyse discriminante linéaire

En se basant sur un de Vincent Vandewalle qui donne une définition de l'analyse discriminante linéaire [7], et d'après "The elements of statistical learning" et "Introduction to statistical learning" [6], on peut définir un modèle de classification de la manière suivante : Prenons un dataset $(\mathbf{x}_i, y_i)$ avec $\mathbf{x}_i \in \mathbb{R}^n$ centrés, et $y_i \in \{1, \dots, k\}$

$$\mathbf{x}_i | (z_i = k) \hookrightarrow \mathcal{N}_n(\mu_k, \Sigma_k)$$

Le but est d'avoir un classifieur linéaire donc on va chercher à exprimer une relation d'appartenance linéaire en $\mathbf{x}$ c'est à dire partitionner le dataset tel que $\mathbf{x}_i \in C_k$ avec C_k l'ensemble des

points de la classe k . Une manière de faire [6] est de considérer que la covariance est commune. On a donc :

$$\mathbf{x}_i | (z_i = k) \hookrightarrow \mathcal{N}_n(\mu_k, \Sigma)$$

Et on définit une matrice de covariance totale $\mathbf{S}_t = \mathbf{S}_b + \mathbf{S}_w$ comme étant la somme des matrices de covariance inter-classes et intra-classes qu'on définit comme :

$$\mathbf{S}_b = \frac{1}{n} \sum_{j=1}^k n_j \mu_j \mu_j^T \quad \text{avec} \quad n_j = \sum_{\mathbf{x}_i \in C_j} 1$$

$$\mathbf{S}_t = \frac{1}{n} \sum_{i=0}^n \mathbf{x}_i \mathbf{x}_i^T = n \mathbf{X} \mathbf{X}^T \quad \text{avec} \quad \mathbf{X} = (x_1, \dots, x_n)$$

On peut alors montrer [11] que pour trouver les solutions à ce problème (c'est à dire les μ_k de chaque classe), il suffit de faire une ACP sur la matrice $\mathbf{S}_t^{-1} \mathbf{S}_b$.

5.2.1 Analyse discriminante linéaire multitâche multiclasse (MT-MLDA)

On va globalement reprendre les notations d'un article qui fut le premier à introduire l'analyse discriminante linéaire multitâche pour faire de la reconnaissance d'image [10]. Notons ici que la MLDA est utilisé dans la littérature scientifique pour faire de la classification sur des électroencéphalogrammes (EEG) [9].

On considère des tâches $t \in \{1, \dots, R\}$ et un dataset $D = \{\tau_1, \dots, \tau_R\}$ centré, avec pour toute tâche t , $\tau_t = \{(\mathbf{x}_{t,n}, l_{t,n})\}_{n=1}^{N_t}$ avec $l_{t,n} \in \{1, \dots, C\}$ est l'étiquette d'appartenance à une classe pour un $\mathbf{x}_{t,n} \in \mathbb{R}^d$ donné, c'est-à-dire au point n pour la tâche t . On va alors considérer qu'il existe une matrice $\mathbf{B}$ commune à toutes les tâches et toutes les classes. On considère ensuite qu'il y a un μ par classe dans chaque tâche. Une tâche se comporte comme une autre classe, l'apprentissage de la LDA multiclasse revient simplement à exprimer les tâches comme une classe. On peut alors écrire la chose suivante :

$$\mathbf{x}_{t,n} | (l_{t,n} = k) \hookrightarrow \mathcal{N}_d(\mathbf{B} \mu_{t,k}, \Sigma)$$

On peut alors concaténer les $\mathbf{x}_{t,i}$ pour une tâche t tel que $\tilde{\mathbf{x}}_t = [\mathbf{x}_{t,1}, \dots, \mathbf{x}_{t,N_t}]^T$ et considérer la matrice indicatrice suivante :

$$(\mathbf{y}_t)_{ij} = \begin{cases} \sqrt{\frac{N_t}{N_{t_j}}} - \sqrt{\frac{N_{t_j}}{N_t}} & \text{si } l_{t,i} = j \\ -\sqrt{\frac{N_{t_j}}{N_t}} & \text{sinon} \end{cases}$$

Tel que N_{t_j} est le nombre d'éléments de la classe j dans la tâche t . Ensuite, $N_t = \sum_{i=1}^C N_{t_i}$ est le nombre d'éléments dans la tâche t .

Par concaténation, on obtient nos matrices et nos quantités finales : $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_R\} \in \mathbb{R}^{N \times d}$ et $\mathbf{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_R\} \in \mathbb{R}^{N \times CR}$ et enfin $N = \sum_{i=1}^R N_i$.

On va alors chercher à exprimer des matrices de covariance comme dans la section d'avant, la seule chose qui va changer sera le nombre de sommations :

La matrice $\mathbf{S}_t$ ne va pas bouger, on va avoir :

$$\mathbf{S}_t = \frac{1}{N} \sum_{t=1}^R \sum_{i=1}^{N_t} \mathbf{x}_{t,i} \mathbf{x}_{t,i}^T = N \mathbf{X} \mathbf{X}^T$$

Pour la matrice $\mathbf{S}_b$, on va réarranger les termes :

$$\mathbf{S}_b = \frac{1}{N} \sum_{t=1}^R \sum_{i=1}^{N_t} \mathbf{B} \mu_{t,i} \mu_{t,i}^T \mathbf{B}^T = \frac{1}{N} \sum_{i=1}^N \mathbf{B} \mu_{T(i)} \mu_{T(i)}^T \mathbf{B}^T$$

Avec $T(i)$ indiquant la tâche et la classe en parcourant le dataset D dans l'ordre des tâches et des classes.

Et en reprenant les notations de 3.1.1, on peut noter : $\mathbf{S}_b = \bar{\Gamma}$.

L'idée pour relier l'article original (et donc 3.1.1) à l'analyse discriminante linéaire va être d'essayer de trouver une bonne décomposition de ces matrices et montrer qu'elles décrivent le même espace. Ceci a des chances d'être possible car on va montrer à la section suivante que la MLDA est équivalente à la MLR sous des hypothèses très faibles, et on peut montrer [8] l'équivalence avec l'approximation de bas rang (ce qui est la première approche de l'article original.)

Le problème majeur est que maintenant, la sortie $\mathbf{y}_t$ n'est plus un réel, c'est une matrice.

5.2.2 Lien entre l'analyse discriminante linéaire et la régression multilinéaire

Il se trouve que l'Analyse discriminante linéaire et la régression multilinéaire sont équivalentes, c'est à dire qu'il existe une certaine matrice indicatrice telle qu'appliquer une régression dessus nous donne exactement les poids qui maximise la classification au sens de la LDA. On peut en retrouver une preuve dans la bibliographie [11].

La preuve se découpe en deux parties, d'abord, on va montrer que notre matrice $\mathbf{Y}$ est bien solution d'une régression puis que cette solution peut s'exprimer à l'aide des matrices $\mathbf{S}_t$ et $\mathbf{S}_b$. La deuxième partie consiste à montrer que cette solution se trouve dans le même espace que celui des solutions du modèle de LDA associé.

On peut esquisser une preuve de l'équivalence entre la LDA et la régression multilinéaire multivariée. Ceci nous donnera des outils pour la suite. Soit $\mathbf{X} \in \mathbb{R}^{n \times d}$ une matrice composée en colonne des vecteurs $\mathbf{x}_i$ qui appartiennent chacun à une classe $t(i)$ à valeur dans $\{1, \dots, R\}$. On définit la matrice de dispersion totale $T = \mathbf{X}\mathbf{X}^T$ car les données sont centrées. On définit une matrice indicatrice $\mathbf{Y} \in \mathbb{R}^{n \times R}$ tel que $(\mathbf{Y})_{ij} = \begin{cases} 1 & \text{si } t(i) = j \\ 0 & \text{sinon} \end{cases}$. De plus, on a N_j points dans

la classe j tel que $n = \sum_{i=1}^R N_i$.

En reprenant les notations de 5.2, on a $\mathbf{S}_t = \mathbf{S}_b + \mathbf{S}_w$ et on peut écrire que la matrice qui contient les poids (les vecteurs μ_i) qui maximisent l'écart entre les classes est $\mathbf{W}^{LDA} = \text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W} (\mathbf{W}^T \mathbf{S}_t \mathbf{W})^{-1})$. Pour noter ça, il faut que la matrice $\mathbf{S}_t$ soit de rang maximale. Si ce n'est pas le cas, on peut prendre le pseudo inverse, en termes de valeur propre, ça revient exactement à prendre une décomposition en valeurs singulière de notre matrice et considérer seulement les valeurs propres non nulles.

Ensuite, de manière assez surprenante, on peut exprimer $\mathbf{S}_b$ sous forme de produit de $\mathbf{Y}$ et $\mathbf{X}$. En effet, on peut remarquer que $\mathbf{Y}^T \mathbf{X}$ est la matrice formée de la somme des éléments de chaque classe. Pour obtenir la moyenne, il suffit de normée par une matrice diagonale qui contient exactement le nombre d'éléments par classe sur sa diagonale. Cette matrice est exactement $\mathbf{Y}^T \mathbf{Y}$. On peut alors noter :

$$\mathbf{S}_b = \mathbf{X}^T \mathbf{Y} (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{X}$$

Et si les classes sont réparties équitablement (même nombre d'éléments dans chaque classe), on a $\mathbf{S}_b = \frac{1}{n} \mathbf{X}^T \mathbf{Y} \mathbf{Y}^T \mathbf{X}$.

Pour éviter ce problème, on pourrait normer $\mathbf{Y}$ pour la norme euclidienne et avoir $\tilde{\mathbf{Y}} = \mathbf{Y}(\mathbf{Y}^T \mathbf{Y})^{-\frac{1}{2}}$ et obtenir $\mathbf{S}_b = \mathbf{X}^T \tilde{\mathbf{Y}} \tilde{\mathbf{Y}}^T \mathbf{X}$.

Maintenant, reste à partir du modèle de régression multivarié sur notre matrice indicatrice. En gardant en tête la remarque faite au paragraphe ci-dessus, afin de simplifier les calculs, on peut considérer que les données sont réparties équitablement dans les classes.

On considère le problème de minimisation suivant : $\mathbf{W}^{MLR} = \arg \min_{\mathbf{B}} \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|^2$. On décompose $\mathbf{Y}$ en un produit de deux matrices dont on fixe le rang max de la première à celui de $\mathbf{Y}$: $\mathbf{Y} = \mathbf{D}\mathbf{F}^T$ avec $\text{rg}(\mathbf{Y}) = p$. Or, comme vu à la section 4.1, si on dispose de $\mathbf{D}$, alors on peut trouver le $\mathbf{F}^T$ optimal par une régression tel que $\mathbf{F}^T = ((\mathbf{X}\mathbf{D})^T \mathbf{X}\mathbf{D})^{-1} (\mathbf{X}\mathbf{D})^T \mathbf{Y}$. On peut alors remplacer $\mathbf{F}^T$ par son expression dans le problème de minimisation : $\|\mathbf{Y} - \mathbf{X}\mathbf{D}((\mathbf{X}\mathbf{D})^T \mathbf{X}\mathbf{D})^{-1} (\mathbf{X}\mathbf{D})^T \mathbf{Y}\|^2$, or, pour une matrice, on a $\|A\|^2 = \text{tr}(AA^T)$, d'où :

$$\mathbf{W}^{MLR} = \arg \min_{\mathbf{D}} \|\mathbf{Y} - \mathbf{X}\mathbf{D}((\mathbf{X}\mathbf{D})^T \mathbf{X}\mathbf{D})^{-1} (\mathbf{X}\mathbf{D})^T \mathbf{Y}\|^2 = \arg \min_{\mathbf{D}} \|\mathbf{Y} - \mathbf{P}\mathbf{Y}\|^2$$

$$\Leftrightarrow \arg \min_{\mathbf{D}} \text{tr}((\mathbf{Y} - \mathbf{P}\mathbf{Y})^T (\mathbf{Y} - \mathbf{P}\mathbf{Y}))$$

$$\Leftrightarrow \arg \min_{\mathbf{D}} \text{tr}(\mathbf{Y}\mathbf{Y}^T - \mathbf{Y}^T \mathbf{P}\mathbf{Y} - \mathbf{Y}^T \mathbf{P}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{P}^T \mathbf{P}\mathbf{Y}) = \arg \min_{\mathbf{D}} [\text{tr}(\mathbf{Y}\mathbf{Y}^T) - \text{tr}(\mathbf{Y}^T \mathbf{P}^T \mathbf{Y})]$$

En effet, $\mathbf{P}$ est une matrice de projection orthogonale, elle est symétrique et idempotente (la vérification est facile, mais fastidieuse.) On peut alors faire la transformation finale de notre problème :

$$\mathbf{W}^{MLR} = \arg \max_{\mathbf{D}} \text{tr}(\mathbf{Y}^T \mathbf{P}^T \mathbf{Y}) = \arg \max_{\mathbf{D}} \text{tr}(\mathbf{Y}^T \mathbf{X}\mathbf{D}((\mathbf{X}\mathbf{D})^T \mathbf{X}\mathbf{D})^{-1} \mathbf{X}\mathbf{D}\mathbf{Y})$$

$$\arg \max_{\mathbf{D}} \text{tr}((\mathbf{D}^T \mathbf{X}^T \mathbf{X}\mathbf{D})^{-1} \mathbf{D}^T \mathbf{X}^T \mathbf{Y}\mathbf{Y}^T \mathbf{X}\mathbf{D}) = \arg \max_{\mathbf{D}} \text{tr}((\mathbf{D}^T \mathbf{S}_t \mathbf{D})^{-1} \mathbf{D}^T \mathbf{S}_b \mathbf{D}) = \mathbf{W}^{LDA}$$

La première ligne est possible car $\mathbf{Y}\mathbf{Y}^T$ ne dépend pas de $\mathbf{D}$ et que passer d'une minimisation à une maximisation revient à changer le signe.

Ceci conclut la preuve pour le cas où les classes contiennent le même nombre d'éléments. Dans le cas contraire, il suffit de remplacer $\mathbf{Y}$ par $\tilde{\mathbf{Y}}$.

Il est intéressant de noter que sous nos hypothèses, et en considérant que l'on dispose d'une bonne matrice $\mathbf{B}$ (qui ici serait plus ou moins équivalent au $\beta_{t(i)}$ du début de ce document), les résultats du théorème 4 (4.1) fonctionnent immédiatement et donc il est possible d'apprendre une nouvelle tâche à notre modèle de MLDA de la même manière qu'on le ferait dans l'article original.

6 Conclusion

Références

- [1] Wang Alessandro, Rinaldo Jingyan. Advanced statistical theory 1, lecture 15, Carnegie-Mellon. https://www.stat.cmu.edu/~arinaldo/Teaching/36755/F17/Scribed_Lectures/F17_1023.pdf, 2017.

- [2] Yuxin Chen. Ele 520 : Mathematics of data science : Spectral methods, Princeton University. https://yuxinchen2020.github.io/ele520_math_data/lectures/spectral_method.pdf, 2020.
- [3] Hsu Daniel. Notes on matrix perturbation and davis-kahan sin theorem, Columbia University. <https://www.cs.columbia.edu/~djhsu/coms4772-f16/lectures/davis-kahan.pdf>.
- [4] Stephane Fotso. Deep neural networks for survival analysis based on a multi-task framework. *arXiv*, 2018.
- [5] Tripuraneni Nilesh, Jin Chi, and Jordan Michael I. Provable meta-learning of linear representation. *arXiv*, 2020.
- [6] Hastie Trevor, Tibshirani Robert, and Friedman Jerome. *The elements of statistical learning*. 2009.
- [7] Vandewalle Vincent. Multi-partitions subspace clustering. *Mathematics*, 2020.
- [8] Cai Xiao, Ding Chris, Nie Feiping, and Huang Heng. On the equivalent of low-rank regressions and linear discriminant analysis based regressions. 2013.
- [9] Zhang Y., Zhou G., Jin J., Zhao Q., Wang X., and Cichocki A. Aggregation of sparse linear discriminant analyses for event-related potential classification in brain-computer interface. *Int J Neural Syst*, 2014.
- [10] Yan Yan, Liu Gaowen, Ricci Elisa, and Sebe Nicu. Multi-task linear discriminant analysis for multi-view action recognition. *ICIP 2013*, 2013.
- [11] Jieping Ye. Least squares linear discriminant analysis. *ICML '07*, 2007.
- [12] Chun-Nam Yu, Russell Greiner, Hsiu-Chin Lin, and Vickie Baracos. Learning patient-specific cancer survival distributions as a sequence of dependent regressors. *arXiv*, 2011.